

EL ABISMO INFINITO

Juego de Rol de Texto y Dungeon Master Inteligente

CREDENCIALES Y ACCESO DEL PROYECTO

Aplicacion Desplegada: <https://juegoiaizanmoros.streamlit.app/>

API Key de Acceso (Google Gemini):

AIzaSyAdJoPY7Q-ZyBEJWMXVvDffzeMCKVs2Mzw

Proyecto de Inteligencia Artificial Avanzada

Dungeon Master Generativo con Arquitectura Streamlit

MAY 2026

PARTE 1: INTRODUCCION Y PROPÓSITO DEL PROYECTO

El Abismo Infinito es un Producto Mínimo Viable (MVP) innovador que automatiza el rol de un Dungeon Master (DM) en juegos de rol de mesa clásicos (como Dungeons & Dragons), utilizando modelos de lenguaje de última generación (LLM) a través de una interfaz web interactiva e inmersiva.

El objetivo principal es ofrecer una experiencia de juego narrativa infinita y personalizada, gobernada por la imaginación del usuario, pero guiada de forma coherente, balanceada y descriptiva por la IA. El sistema interactúa directamente con el jugador, describiendo el entorno con un lenguaje épico de fantasía oscura, evaluando las acciones del usuario y proponiendo alternativas estructuradas sin arrebatarse el control sobre sus propias decisiones.

Este proyecto destaca por aplicar técnicas avanzadas de optimización de contexto e ingeniería de prompts para solucionar las dos barreras más comunes en el uso gratuito de APIs de inteligencia artificial:

1. La pérdida de coherencia o memoria a corto plazo tras varios turnos de conversación.
2. El bloqueo de servicios por exceder los límites de cuotas en planes gratuitos (Error 429).

PARTE 2: ARQUITECTURA Y INTEGRACIONES DE MODELOS (2026)

El core de la aplicación está construido sobre Python 3.x y Streamlit, lo que permite un renderizado reactivo y fluido de la interfaz de chat. La arquitectura de conexión de modelos de lenguaje está diseñada de forma modular, permitiendo al usuario cambiar en tiempo real entre tres motores LLM distintos:

A) Google Gemini (Recomendado): Integra el SDK oficial de Google. En el año 2026, la plataforma ha actualizado sus modelos e interfaces de v1beta, por lo que el sistema está optimizado para trabajar con:

- gemini-2.5-flash: El modelo de alta velocidad, ultra eficiente y con cuotas amplias en la capa gratuita.
- gemini-2.5-pro: Modelo altamente analítico, excelente para campañas complejas pero con cuotas estrictas.
- gemini-3.5-flash: Modelo de última generación con un balance superior entre latencia y coherencia narrativa.
- gemini-3.1-pro: Variante avanzada para deducciones detalladas y tramas profundas.

B) Groq: Proporciona respuestas ultrarrápidas de baja latencia utilizando el modelo de código abierto llama3-8b-8192, ideal para mantener un flujo de chat instantáneo sin coste alguno.

C) OpenAI: Conector compatible con GPT-3.5 Turbo o superior para jugadores que prefieren la consistencia del ecosistema de OpenAI.

PARTE 3: GESTION DE MEMORIA (CONVERSATION BUFFER WINDOW)

Los modelos de lenguaje son apastridas (stateless); no recuerdan el contenido de los mensajes anteriores. Para simular memoria, los sistemas tradicionales reinyectan todo el historial en cada turno. Sin embargo, en el plan gratuito de las APIs (como Gemini o OpenAI), esto causa una saturacion veloz de los limites de tokens de entrada disponibles por minuto, resultando en bloqueos constantes.

Para solucionar este reto, El Abismo Infinito implementa un algoritmo personalizado de ConversationBufferWindowMemory (inspirado en frameworks como LangChain):

1. Estructura de Mensajes Fija: Se mantiene permanentemente el primer mensaje (System Prompt) en la posicion 0. Este prompt le enseña a la IA su rol estricto como Dungeon Master, las reglas de interaccion (no actuar por el usuario y ofrecer 3 opciones de viñetas al final).
2. Ventana Deslizante (Slider de Memoria): El usuario puede elegir a traves de un control deslizante interactivo en la barra lateral el numero de turnos recordados (N). Un turno consta de un par de mensajes (Accion del usuario + Respuesta del DM).
3. Filtro Dinamico de Contexto: La funcion `apply_memory_buffer` recorta el historial para mantener solo el System Prompt y los ultimos $N*2$ mensajes. Todos los mensajes intermedios mas antiguos se descartan del buffer arrojado al LLM. Esto garantiza que el consumo de tokens sea lineal y controlado, extendiendo infinitamente la partida sin sobrecargar los limites de la API.

PARTE 4: MITIGACION DE ERRORES 429 Y MEJORAS DE UX

Cuando multiples peticiones rapidas o cargas extensas saturan la cuota del nivel gratuito, la API de Google retorna un codigo de estado 429 (Too Many Requests / Resource Exhausted). Para solventar esto y ofrecer una experiencia premium, se han desarrollado dos componentes criticos:

A) Monitor de Consumo de Memoria en Barra Lateral:

A traves de la funcion `estimate_context_size`, el sistema calcula en tiempo real el tamaño en caracteres y palabras del historial que se enviara en el siguiente turno. El usuario recibe un feedback visual inmersivo:

- Verde (Bajo/Seguro): Menos de 3000 caracteres. Garantiza partidas estables.
- Amarillo (Moderado): De 3000 a 7000 caracteres. Riesgo bajo de saturacion.
- Rojo (Alto/Peligroso): Mas de 7000 caracteres. Alerta al usuario para reducir el buffer antes del error.

B) Tarjeta de Error Tematizada RPG:

Si a pesar de todo la API arroja un error 429, el codigo intercepta la excepcion (`google_exceptions.ResourceExhausted`) y la transforma en un pergamino digital estilizado mediante HTML y CSS. El error deja de ser un traceback tecnico hostil y se convierte en un evento de rol: 'El Dungeon Master esta

agotado y necesita recuperar mana'.

PARTE 5: CREDENCIALES DE ACCESO Y ENLACES

Para facilitar la evaluacion e interaccion directa con el MVP del Dungeon Master de IA, se disponen de los siguientes recursos clave de acceso libre:

1. APLICACION DESPLEGADA (URL STREAMLIT SHARE):

La aplicacion esta hosteada de forma publica y es accesible desde cualquier navegador moderno en:

<https://juegoiaizanmoros.streamlit.app/>

2. CREDENCIAL DE ACCESO (GOOGLE AI STUDIO API KEY):

Para que la aplicacion cobre vida, se requiere una llave de acceso. Puedes pegar la siguiente clave directamente en el panel lateral 'Grimorio del DM' en el campo 'Ingresa tu API Key' para activar los motores de Gemini:

API KEY: AlzaSyAdJoPY7Q-ZyBEJWMXVvDffzeMCKVs2Mzw

Esta llave esta configurada en el plan gratuito para propósitos de testeo. Se recomienda usar el modelo gemini-2.5-flash para maxima velocidad y estabilidad.

PARTE 6: GUIA DE INSTALACION Y EJECUCION LOCAL

Si deseas clonar y ejecutar este proyecto en tu propia maquina, sigue estos pasos:

Paso 1: Clonar el repositorio de GitHub:

```
git clone https://github.com/IzanMoros/Juegola.git
cd Juegola/proyecto_ia_mvp
```

Paso 2: Instalar las dependencias de Python necesarias:

```
pip install -r requirements.txt
```

Paso 3: Arrancar la aplicacion con Streamlit:

En Windows, ejecuta:

```
py -m streamlit run app.py
```

En MacOS/Linux, ejecuta:

```
python -m streamlit run app.py
```

Paso 4: Abre tu navegador en la direccion local suministrada (normalmente <http://localhost:8501>), ingresa la API Key suministrada en este documento en la barra izquierda, selecciona tu modelo preferido y ¡da inicio a tu aventura!